



Inteligência Computacional

Projeto – Fase 1 – Fashion Mnist



Licenciatura Eng. Informática

3ºAno/1ºSemestre

2020/2021

Carolina Ferreira nº 2018018459

Eduardo Pina nº2017010181

Cap. 1: Descrição do caso de estudo e objetivos do problema

No âmbito na unidade curricular de Inteligência Computacional foi-nos proposta a realização de um trabalho prático onde aplicássemos os conhecimentos adquiridos ao longo do semestre. Dos temas/repositórios que nos foram propostos, escolhemos o Fashion Mnist.

O objetivo deste trabalho consiste na implementação de uma rede neuronal capaz de classificar corretamente peças de roupas sendo que existem 10 classes: ***T-shirt/top, Trouser, Pullover, Dress, Coat, Sandal, Shirt, Sneaker, Bag, Ankle boot.***

O dataset conta com 60000 exemplos para treino e 10000 exemplos para teste. Cada imagem é representada por uma matriz 28x28 “grayscale”. Os valores de pixéis são inteiros entre 0 e 255. Para o desenvolvimento deste trabalho, foram-nos fornecidos ficheiros Excel das imagens convertidas para decimal para teste e treino, como também, 4 ficheiros binários que continham diversas imagens de teste e treino juntamente com os seus labels correspondentes.

Ao longo dos testes fomos avaliando várias topologias e características de modo a perceber qual é a melhor rede neuronal a usar assim como o impacto da variação de parâmetros como o número de neurónios, número de camadas e coeficiente de aprendizagem na precisão e na sensibilidade.

Cap. 2: Descrição da Implementação dos Algoritmos

O código inicia-se com a função “loadMNISTImages()” que faz o upload dos ficheiros binários para identificar quais as matrizes que iremos usar para teste e para treino. De seguida selecionamos um conjunto de 25 amostras (as primeiras da matriz) para ver de que modo é que as peças de roupa estão desenhadas/apresentadas. Com o upload das matrizes dos ficheiros binários, começamos a preparar o treino da rede para avaliar o seu desempenho. Para avaliar o desempenho de uma das redes, adicionamos algumas características – função de treino e coeficiente de aprendizagem - que permitem obter a performance da mesma.

Ao executar o programa, recorrendo à função “plotconfusion()” é mostrada a matriz de confusão e são apresentados os resultados métricos uma vez que temos em mãos um problema de classificação:

- Precision/precisão = $\text{true positives} / (\text{true positives} + \text{false positives})$
p.e: neste contexto, a precisão pode ser a percentagem de t-shirts identificadas corretamente no total de elementos considerados como t-shirt (os que realmente são + os que não são, mas foram identificados como tal).
- Recall/sensibilidade = $\text{true positives} / (\text{true positives} + \text{false negatives})$
p.e: neste contexto, a sensibilidade pode ser a percentagem de t-shirts identificadas corretamente no total de elementos que realmente correspondem a t-shirts.
- Accuracy = $\text{number of correct predictions} / \text{total number of predictions}$
p.e: a accuracy corresponde à percentagem de acertos (tanto verdadeiros como falsos) no total de previsões feitas.
- Especificidade (espec) = $\text{true negatives} / (\text{false positives} + \text{true negatives})$
p.e: a especificidade corresponde à percentagem de negativos verdadeiros (não t-shirts são corretamente identificadas como não sendo t-shirt) no total de todos os elementos que não são t-shirts.
- f-measure
- AUC

Cap. 3: Análise de Resultados

De forma a chegar a conclusões sobre qual a arquitetura de rede MLP mais apropriada ao problema, ou seja, qual é a que gera valores mais altos de precisão, sensibilidade e especificidade, assim como qual o melhor valor de coeficiente de aprendizagem, número de neurónios e de camadas ideal, foi realizada uma extensa bateria de testes variando sempre estes parâmetros. No que diz respeito às redes MLP, testámos a “Patternet” e a “FeedForwardNet”. Não fizemos análise de resultados para a Newff (feed-forward backpropagation network) porque após alguma pesquisa apercebemo-nos de que não seria indicada ao Fashion Mnist. Quanto a funções de treino, testámos a traingd e a traingdx (ambas do tipo Gradient descent) sendo que a

diferença entre elas reside no facto de a traingdx gerar valores de acordo com o “momentum” de descida do gradiente e uma taxa de aprendizagem adaptativa.

	A	B	C	D	E	F	G	H	I	J	K
1	VARIA Nº DE NEURONIOS		FUNÇÃO DE TREINO: traingd								
2											
3	PATTERNET	10 neuronios	1 camada	coeficiente= 0.01							
4											
5	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
6	Precision	0.778947	0.886364	0.657609	0.555046	0.018519	0.583908	0.420263	0.681583	0.273692	0.634318
7	Recall	0.148000	0.663000	0.242000	0.847000	0.002000	0.762000	0.224000	0.792000	0.722000	0.902000
8	Accuracy	0.910600	0.957900	0.911600	0.916800	0.899600	0.921900	0.891500	0.942200	0.780600	0.938200
9	Especificidade	0.913150	0.963575	0.921304	0.981945	0.899110	0.972628	0.918031	0.976465	0.962239	0.988575
10	AUC	0.846049	0.924970	0.789456	0.768495	0.458814	0.778268	0.669147	0.829024	0.617965	0.811447
11											
12	-----Media -----										
13	0.5490248 Precision Media										
14	0.5304000 Recall Media										
15	0.9060800 Accuracy Media										
16	0.9497023 Especificidade Media										
17	Fmesure-----ln										
18	0.539552										
19											
20											
21	PATTERNET	20 neuronios	1 camada	coeficiente= 0.01							
22											
23	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
24	Precision	0.684018	0.908818	0.585440	0.758376	0.546549	0.752841	0.441860	0.788224	0.858149	0.863415
25	Recall	0.749000	0.907000	0.579000	0.747000	0.681000	0.795000	0.247000	0.830000	0.853000	0.885000
26	Accuracy	0.940300	0.981600	0.916900	0.950900	0.911600	0.953400	0.893500	0.960700	0.971200	0.974500
27	Especificidade	0.971814	0.989669	0.953279	0.971936	0.963560	0.977080	0.920241	0.980999	0.983678	0.987187
28	AUC	0.827916	0.949243	0.769360	0.865156	0.755054	0.864960	0.681051	0.884612	0.920913	0.925301
29											
30	-----Media -----										
31	0.7187689 Precision Media										
32	0.7273000 Recall Media										
33	0.9454600 Accuracy Media										
34	0.9699442 Especificidade Media										
35	Fmesure-----ln										
36	0.723009										
37											
39	PATTERNET	30 neuronios	1 camada	coeficiente= 0.01							
40											
41	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
42	Precision	0.739821	0.943691	0.660851	0.757827	0.624884	0.782168	0.478972	0.781049	0.893253	0.861300
43	Recall	0.745000	0.905000	0.606000	0.823000	0.673000	0.772000	0.410000	0.849000	0.887000	0.888000
44	Accuracy	0.948300	0.985100	0.929500	0.956000	0.926900	0.955700	0.896400	0.961100	0.978100	0.974500
45	Especificidade	0.971645	0.989492	0.956622	0.980144	0.963353	0.974703	0.935477	0.983058	0.987454	0.987513
46	AUC	0.855733	0.966592	0.808736	0.868985	0.794119	0.878436	0.707224	0.882054	0.940353	0.924406
47											
48	-----Media -----										
49	0.7523815 Precision Media										
50	0.7558000 Recall Media										
51	0.9511600 Accuracy Media										
52	0.9729461 Especificidade Media										
53	Fmesure-----ln										
54	0.754087										
55											
56											
57	PATTERNET	50 neuronios	1 camada	coeficiente= 0.01							
58											
59	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
60	Precision	0.685284	0.962225	0.626653	0.779835	0.618147	0.767164	0.486270	0.808636	0.901169	0.835052
61	Recall	0.773000	0.917000	0.616000	0.758000	0.654000	0.771000	0.425000	0.824000	0.848000	0.891000
62	Accuracy	0.941800	0.988100	0.924900	0.954400	0.925000	0.953700	0.897600	0.962900	0.975500	0.971500
63	Especificidade	0.974414	0.990826	0.957414	0.973195	0.961306	0.974541	0.936993	0.980403	0.983221	0.987798
64	AUC	0.829849	0.976525	0.792033	0.876515	0.789727	0.870853	0.711632	0.894519	0.942195	0.911425
65											
66	-----Media -----										
67	0.7470435 Precision Media										
68	0.7477000 Recall Media										
69	0.9495400 Accuracy Media										
70	0.9720111 Especificidade Media										
71	Fmesure-----ln										
72	0.754087										
73											
74											
75	PATTERNET	250 neuronios	1 camada	coeficiente= 0.01							
76											
77	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
78	Precision	0.734328	0.952577	0.672098	0.776459	0.668945	0.852590	0.507968	0.861000	0.907048	0.871694
79	Recall	0.739000	0.924000	0.660000	0.785000	0.685000	0.856000	0.510000	0.861000	0.888000	0.890000
80	Accuracy	0.947100	0.987800	0.933800	0.955900	0.934600	0.970800	0.901600	0.972200	0.979700	0.975900
81	Especificidade	0.970873	0.991584	0.962298	0.976082	0.964906	0.983993	0.945531	0.984556	0.987585	0.987749
82	AUC	0.852601	0.972080	0.817198	0.876270	0.816926	0.918291	0.726750	0.922778	0.947316	0.929722
83											
84	-----Media -----										
85	0.7797000 Precision Media										
86	0.7804708 Recall Media										
87	0.9559400 Accuracy Media										
88	0.9755156 Especificidade Media										
89	Fmesure-----ln										
90	0.780085										

Variando para FeedForwardNet, considerando que os melhores resultados obtidos na Patternet para o nº de neurónios foram com os valores 50 e 250:

152	FEEDFORWARDNET	50 neurónios	1 camada	coeficiente= 0.01							
153											
154	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
155	Precision	0.763393	0.725926	0.484142	0.571429	0.515667	0.565183	0.352691	0.740119	0.860710	0.853075
156	Recall	0.513000	0.882000	0.519000	0.748000	0.576000	0.711000	0.249000	0.749000	0.655000	0.749000
157	Accuracy	0.935400	0.954900	0.896600	0.918700	0.903500	0.916400	0.879200	0.948600	0.954900	0.962000
158	Especificidade	0.947792	0.986568	0.946125	0.971004	0.952268	0.966941	0.919195	0.972074	0.962658	0.972484
159	AUC	0.855592	0.856247	0.715133	0.771217	0.733968	0.766062	0.635943	0.856096	0.911684	0.912780
160											
161	-----Media -----										
162	0.6351000 Precision Media										
163	0.6432333 Recall Media										
164	0.9270200 Accuracy Media										
165	0.9597110 Especificidade Media										
166	Fmesure-----In										
167	0.639141										
168											
169											
170	FEEDFORWARDNET	250 neurónios	1 camada	coeficiente= 0.01							
171											
172	Métrica/Classe	0	1	2	3	4	5	6	7	8	9
173	Precision	0.584354	0.750433	0.548105	0.633010	0.515608	0.644726	0.361446	0.681368	0.691803	0.719745
174	Recall	0.620000	0.866000	0.376000	0.652000	0.479000	0.764000	0.300000	0.757000	0.633000	0.791000
175	Accuracy	0.917900	0.957800	0.906600	0.927400	0.902900	0.934300	0.877000	0.940300	0.935100	0.948300
176	Especificidade	0.957490	0.984852	0.933004	0.961204	0.942564	0.973227	0.923664	0.972663	0.959604	0.976519
177	AUC	0.770922	0.867643	0.740555	0.797107	0.729086	0.808977	0.642555	0.827015	0.825704	0.848132
178											
179	-----Media -----										
180	0.6130599 Precision Media										
181	0.6238000 Recall Media										
182	0.9247600 Accuracy Media										
183	9.584792 Especificidade Media										
184	Fmesure-----In										
185	0.618383										
186											

Variando o valor do coeficiente de aprendizagem anteriormente aplicado com o valor padrão 0.01 para 0.1, 0.4 e 0.9:

VARIA COEFICIENTE		FUNÇÃO DE TREINO: traingd								
PATTERNET	50 neuronios	1 camada	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.775073	0.971516	0.746680	0.831068	0.733138	0.914345	0.603875	0.892927	0.920197	0.905550
Recall	0.796000	0.955000	0.731000	0.856000	0.750000	0.886000	0.919300	0.909000	0.934000	0.930000
Accuracy	0.956500	0.992700	0.948300	0.968200	0.947700	0.980300	0.919300	0.980000	0.985300	0.983300
Especificidade	0.956500	0.995009	0.970181	0.983946	0.972151	0.987377	0.951604	0.989869	0.992654	0.992199
AUC	0.876169	0.983263	0.858430	0.907507	0.852644	0.950861	0.777740	0.941398	0.956426	0.948874
-----Media -----										
0.8294369 Precision Media										
0.8308000 Recall Media										
0.9661600 Accuracy Media										
0.9812255 E especificidade Media										
Fmesure-----In										
0.830118										
PATTERNET	50 neuronios	1 camada	coeficiente = 0.40							
					epocas 36					
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.731034	0.910112	0.672258	0.748806	0.578035	0.824447	0.401267	0.719483	0.906780	0.844796
Recall	0.742000	0.891000	0.521000	0.784000	0.700000	0.949900	0.380000	0.890000	0.856000	0.909000
Accuracy	0.946900	0.980300	0.926700	0.952100	0.918900	0.949900	0.881300	0.954300	0.976800	0.974200
Especificidade	0.971285	0.987917	0.948076	0.975874	0.965866	0.960351	0.931514	0.987447	0.984099	0.989803
AUC	0.851160	0.949015	0.810167	0.862340	0.771951	0.892399	0.666391	0.853465	0.945439	0.917299
-----Media -----										
0.7307000 Precision Media										
0.7337018 Recall Media										
0.9461400 Accuracy Media										
0.9702233 E especificidade Media										
Fmesure-----In										
0.732198										
PATTERNET	50 neuronios	1 camada	coeficiente = 0.90							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.804984	0.986957	0.628963	0.762577	0.636861	0.797588	0.520280	0.913386	0.918511	0.899202
Recall	0.743000	0.908000	0.734000	0.864000	0.698000	0.926000	0.372000	0.812000	0.913000	0.901000
Accuracy	0.956300	0.989600	0.930100	0.959500	0.930000	0.969100	0.902900	0.973500	0.983200	0.980000
Especificidade	0.971687	0.989868	0.963986	0.984662	0.966083	0.991628	0.932364	0.979366	0.990340	0.988998
AUC	0.888335	0.988412	0.799424	0.873620	0.801472	0.894608	0.726322	0.946376	0.954425	0.944100
-----Media -----										
0.7869308 Precision Media										
0.7871000 Recall Media										
0.9574200 Accuracy Media										
0.9764880 E especificidade Media										
Fmesure-----In										
0.787015										

Comparação entre as funções de treino `traingd` e `trainidx` com os restantes parâmetros com valores iguais:

PATTERNET	250 neuronio	1 camada	coeficiente= 0.01	FUNÇÃO DE TREINO: <code>traingd</code>						
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.734328	0.952577	0.672098	0.776459	0.688945	0.852590	0.507968	0.861000	0.907048	0.871694
Recall	0.738000	0.924000	0.660000	0.785000	0.685000	0.856000	0.510000	0.861000	0.888000	0.890000
Accuracy	0.947100	0.987800	0.933800	0.955900	0.934600	0.970800	0.901600	0.972200	0.979700	0.975900
Especificidade	0.970873	0.991584	0.962298	0.976082	0.964906	0.983993	0.945531	0.984556	0.987585	0.987749
AUC	0.852601	0.972080	0.817198	0.876270	0.816326	0.918291	0.726750	0.922778	0.947316	0.929722
-----Media -----										
0.7797000 Precision Media										
0.7804708 Recall Media										
0.9559400 Accuracy Media										
0.9755156 Especificidade Media										
Fmeasure-----In										
0.780085										

PATTERNET	250 neuronios	1 camada	coeficiente= 0.01	FUNÇÃO DE TREINO: <code>trainidx</code>						
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.792969	0.975410	0.737705	0.827290	0.741294	0.921466	0.595657	0.884653	0.932528	0.903195
Recall	0.812000	0.952000	0.720000	0.867000	0.745000	0.880000	0.576000	0.905000	0.926000	0.933000
Accuracy	0.960000	0.992800	0.946400	0.968600	0.948500	0.980500	0.918500	0.978700	0.985900	0.983300
Especificidade	0.979055	0.994681	0.968972	0.985143	0.971651	0.986733	0.953061	0.989417	0.991784	0.992528
AUC	0.886012	0.985045	0.853338	0.906217	0.856472	0.954099	0.774359	0.937035	0.962156	0.947861
-----Media -----										
0.8312165 Precision Media										
0.8316000 Recall Media										
0.9663200 Accuracy Media										
0.9813025 Especificidade Media										
Fmeasure-----In										
0.831408										

Variando o número de camadas mantendo o número de neurónios (100):

VARIA Nº DE CAMADAS		FUNÇÃO DE TREINO: <code>traingd</code>								
PATTERNET	(50 , 50)	2 camadas	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.768351	0.977178	0.703668	0.823643	0.732230	0.921488	0.599542	0.878405	0.920556	0.908374
Recall	0.806000	0.942000	0.729000	0.850000	0.752000	0.892000	0.524000	0.903000	0.927000	0.922000
Accuracy	0.956300	0.992000	0.942200	0.966800	0.947700	0.981600	0.917400	0.977800	0.984700	0.984700
Especificidade	0.978326	0.993581	0.969768	0.983274	0.972362	0.988043	0.947841	0.989189	0.991883	0.991319
AUC	0.873339	0.985380	0.836718	0.903459	0.852296	0.954765	0.773692	0.933797	0.956219	0.949847
-----Media -----										
0.8233435 Precision Media										
0.8247000 Recall Media										
0.9649400 Accuracy Media										
0.9805585 Especificidade Media										
Fmeasure-----In										
0.824021										

PATTERNET	(25 , 25 , 50)	3 camadas	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.773547	0.975283	0.730108	0.809893	0.682883	0.913203	0.588608	0.886811	0.923000	0.894535
Recall	0.772000	0.947000	0.679000	0.835000	0.758000	0.876000	0.558000	0.901000	0.923000	0.933000
Accuracy	0.954600	0.992300	0.942800	0.963900	0.940600	0.979900	0.916800	0.978600	0.984600	0.982300
Especificidade	0.974672	0.994130	0.964609	0.981603	0.972778	0.986294	0.951171	0.988980	0.991444	0.992520
AUC	0.874110	0.984707	0.847358	0.895748	0.827831	0.952748	0.769889	0.937896	0.957222	0.943527
-----Media -----										
0.8183870 Precision Media										
0.8182000 Recall Media										
0.9636400 Accuracy Media										
0.9798202 Especificidade Media										
Fmeasure-----In										
0.818293										

PATTERNET	(25 , 25 , 25 , 25	4 camadas	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.757576	0.973113	0.719475	0.818357	0.675824	0.908530	0.575326	0.879803	0.921236	0.899512
Recall	0.800000	0.941000	0.713000	0.847000	0.738000	0.884000	0.884000	0.893000	0.924000	0.922000
Accuracy	0.954400	0.991500	0.943500	0.965900	0.938400	0.979500	0.912700	0.977100	0.984500	0.981900
Especificidade	0.977639	0.993468	0.968143	0.982934	0.970588	0.987150	0.943759	0.988091	0.991553	0.991309
AUC	0.867607	0.983291	0.843809	0.900646	0.823206	0.947840	0.759543	0.933947	0.956395	0.945411
-----Media -----										
0.8147000 Precision Media										
0.8128753 Recall Media										
0.9629400 Accuracy Media										
0.9794634 Especificidade Media										
Fmeasure-----In										
0.813787										
FEEDFORWARDNET	(50 , 50)	2 camadas	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.699913	0.983033	0.631628	0.741533	0.601653	0.848907	0.558962	0.855874	0.881023	0.883477
Recall	0.800000	0.927000	0.679000	0.832000	0.728000	0.854000	0.237000	0.867000	0.896000	0.925000
Accuracy	0.945700	0.991100	0.928300	0.954200	0.924600	0.970200	0.905000	0.972100	0.977500	0.980300
Especificidade	0.977419	0.991940	0.964034	0.981077	0.969056	0.983767	0.920322	0.985201	0.988423	0.991623
AUC	0.838666	0.987486	0.797831	0.861305	0.785354	0.916337	0.739642	0.920537	0.934723	0.937550
-----Media -----										
0.7745000 Precision Media										
0.7686001 Recall Media										
0.9549000 Accuracy Media										
0.9752860 Especificidade Media										
Fmeasure-----In										
0.771539										
FEEDFORWARDNET	(25 , 25 , 50)	3 camadas	coeficiente= 0.10							
Métrica/Classe	0	1	2	3	4	5	6	7	8	9
Precision	0.640800	0.471661	0.369508	0.000000	0.230366	0.831199	0.278689	0.759191	0.732952	0.837545
Recall	0.801000	0.957000	0.841000	0.000000	0.044000	0.714000	0.017000	0.826000	0.900000	0.928000
Accuracy	0.935200	0.888500	0.840600	0.899700	0.889700	0.956900	0.897300	0.956400	0.966500	0.974800
Especificidade	0.977257	0.994605	0.979415	0.899970	0.902538	0.968712	0.901097	0.980476	0.988720	0.991903
AUC	0.809029	0.733133	0.674461	0.449985	0.566452	0.899956	0.589893	0.869833	0.890836	0.914724
-----Media -----										
0.5211911 Precision Media										
0.6028000 Recall Media										
0.9205600 Accuracy Media										
0.9584693 Especificidade Media										
Fmeasure-----In										
0.559033										

Aumentando o número de neurónios em 3 camadas para avaliar se os valores melhoram relativamente aos usados anteriormente em 3 camadas:

PATTERNET	(50 , 50 , 100)	3 camadas	coeficiente= 0.1								136 épocas
Métrica/Classe	0	1	2	3	4	5	6	7	8	9	
Precision	0.743733	0.977107	0.645810	0.813166	0.667315	0.888008	0.497980	0.885331	0.917659	0.892338	
Recall	0.801000	0.939000	0.578000	0.840000	0.686000	0.896000	0.493000	0.857000	0.925000	0.920000	
Accuracy	0.952500	0.991700	0.926100	0.964700	0.934400	0.978300	0.899600	0.974600	0.984200	0.980900	
Especificidade	0.977698	0.993251	0.953652	0.982157	0.965002	0.988433	0.943729	0.984167	0.991659	0.991080	
AUC	0.860715	0.985179	0.799731	0.897661	0.816159	0.938220	0.720854	0.934749	0.954659	0.941709	
-----Media -----											
0.7928445 Precision Media											
0.7935000 Recall Media											
0.9587000 Accuracy Media											
0.9770830 Especificidade Media											
Fmeasure-----In											
n 793172											

Cap. 4: Conclusões

Os melhores valores obtidos em cada parâmetro a avaliar estão assinalados com um retângulo vermelho.

As tabelas apresentadas ao longo deste relatório constituem apenas uma parte da totalidade que se encontra em anexo no ficheiro de Excel, no entanto, consideramos que são as tabelas-chave para tirarmos as nossas conclusões finais.

Após análise exaustiva das várias tabelas, concluímos que:

- a arquitetura de rede com melhores valores, foi a **Patternet** uma vez que mantendo os restantes parâmetros, mas alterando para a **FeedForwardNet**, as médias obtidas foram sempre inferiores;
- aumentando o número de neurónios obtivemos melhores valores uma vez que para números baixos a precisão e a sensibilidade apresentam-se baixas, o que significa que identifica erradamente muitos elementos (muitos falsos positivos);
- o coeficiente de aprendizagem com melhores resultados foi no valor de 0.1. Como testamos para os valores 0.01, 0.4 e 0.9, não podemos concluir que quanto menor o coeficiente, melhores os resultados obtidos, mas que isso é verdade até um certo limite;
- entre as funções de treino traingd e traingdx, a traingdx apresentou não só melhores resultados como também melhor performance em relação ao número de épocas;
- variando o número de camadas, mas mantendo o número de neurónios, menor número de camadas leva a melhores resultados, como seria de esperar.
- a especificidade foi sempre superior a 95% o que indica uma grande percentagem de acerto no que diz respeito aos negativos verdadeiros;

NOTA: Aumentando o número de neurónios por camada, esperávamos um aumento significativo das médias de precisão e sensibilidade, mas não foi o obtido. Os resultados foram inconclusivos uma vez que foram inconstantes nos vários testes realizados.

Referências

Fashion Mnist (version 4, 2017). Zalando Research. Kaggle. Disponível em: <https://www.kaggle.com/zalando-research/fashionmnist>

How to Choose Evaluation Metrics for Classification Models. Data Science Blogathon, october 11, 2020. Disponível em: <https://www.analyticsvidhya.com/blog/2020/10/how-to-choose-evaluation-metrics-for-classification-model/>

Huilgol, P. Precision vs. Recall – An Intuitive Guide for Every Machine Learning Person. September 4, 2020. Disponível em: <https://www.analyticsvidhya.com/blog/2020/09/precision-recall-machine-learning/>